

Linear predictors

Affine function

def: $L_d = \{h_{w,b} : w \in R^d, b \in R\}$ where $h_{w,b}(w) = \langle w, x \rangle + b$ | prodotto scalare tra il parametro w e l'input x | b è il bias

altra notazione $L_d = \{x \mapsto \langle w, x \rangle + b : w \in R^d, b \in R\}$

Halfspaces

$HS_d = \text{sign} \circ L_d = \{x \mapsto \text{sign}(h_{w,b}(x)) : h_{w,b} \in L_d\}$

sign è una funzione che ritorna +1 se la funzione è ≥ 0 , altrimenti -1.

se $b = 0$ è omogeneo

$\text{VCDim}(HS_d \text{ omogeneo}) = d$ $\text{VCDim}(HS_d) = d + 1$

la classe degli halfspaces può essere espressa come linear programming: ...

Perceptrons

è un algoritmo che risolve la classe degli halfspaces costruisce una serie di vettori w_1, w_2, \dots all'inizio w è inizializzato con soli 0 ad ogni iterazione si trova quali dati sono fuori dalla valutazione e si modifica w per includerli

$$w^{t+1} = w^t + y_i * x_i$$

teorema: assume that $(x_1, y_1), \dots, (x_m, y_m)$ is separable, let $B = \min\{\|w\| : \forall i \in [m], y_i < \langle w, x_i \rangle \geq 1\}$, and let $R = \max_i \|x_i\|$. Then, the perc algo stops after at most $(RB)^2$ iteration, and when it stops it holds that $\forall i \in [m], y_i < \langle w * t, x_i \rangle > 0$.

il teorema dice che l'algoritmo è sicuro che converge e che la complessità dipende principalmente da B che in alcuni casi è esponenziale in d , in quel caso meglio definire il problema come un programma lineare.

Linear regression

Simile agli halfspace ma definisce una funzione affine invece che una disuguaglianza

$$H_{\text{reg}} = L_d = \{x \mapsto \langle w, x \rangle + b : w \in R^d, b \in R\}$$

la loss function però non può essere binaria come le precedenti

squared-loss fun : $l(h, (x, y)) = (h(x) - y)^2$

la empirical risk function è chiamata Mean Squared Error ed è

$$L_s(h) = \frac{1}{m} \sum_{i=1}^m (h(x_i) - y_i)^2$$

Esistono diverse loss function, per esempio la absolute value loss fun $|h(x) - y|$ e la sua ERM rule può essere implementata con un programma lineare.

Visto che la linear regression non è un predittore binario non possiamo usare la VCDim per capire la sua complessità.

Least Squares

è l'algo che risolve il ERM problem per la hypo class del linear regression predictors wrt the squared loss.

$$\operatorname{argmin}_w L_s(h) = \operatorname{argmin}_w \frac{1}{m} \sum_{i=1}^m (< w, x_i > -y_i)^2$$

per risolvere il problema facciamo il gradiente della funzione obbiettivo comparandola a zero.

$$\nabla L_s(h) = \frac{2}{m} \sum_{i=1}^m (< w, x_i > -y_i) * x_i = 0$$

Si può risolvere vedendolo come un sistema lineare $Aw = b$.

La soluzione è $w = A^{-1}b$ se A è invertibile.

Si possono esprimere funzioni polinomiali aumentando il grado n , riuscendo quindi a esprimere funzioni più complicate $H_{\text{poly}}^n = \{x \mapsto p(x)\}$